

SISTEMA INTELIGENTE HÍBRIDO PARA LA CLASIFICACIÓN DE CALIDAD DEL VINO TINTO

Inducción de Reglas con Algoritmo PRISM, Sistema de Inferencia Difusa Mamdani y Optimización Continua Mediante Algoritmos Genéticos

Proyecto de Inteligencia Artificial

Facultad de Ingeniería

Clasificación de Calidad Enológica (Wine Quality Dataset)

27 de septiembre de 2026

Resumen

En este trabajo se diseña, fundamenta e implementa un sistema inteligente híbrido para la clasificación de la calidad del vino tinto a partir de sus propiedades fisicoquímicas (*Wine Quality Dataset*). La discretización rígida tradicional sobre variables continuas adolece del denominado *problema de frontera* (*boundary problem*), provocando que observaciones con diferencias insignificantes caigan en categorías opuestas y degradando severamente la capacidad de generalización en conjuntos de prueba independientes (exactitud de apenas 35.00 % bajo reglas rígidas). Para solventar esta limitación, se propone una arquitectura en etapas: (1) Preprocesamiento y discretización inicial por terciles estadísticos; (2) Inducción modular de reglas mediante el algoritmo de recubrimiento secuencial **PRISM**, evaluando métricas formales de Confianza, Soporte, Cobertura y *Lift*; (3) Transformación a un **Sistema de Inferencia Difusa Tipo Mamdani** estructurado en sus cuatro etapas canónicas (Fuzzificación, Inferencia con T-norma Mínimo, Agregación y Defuzzificación por Centroides y Máxima Pertenencia); (4) Optimización evolutiva mediante un **Algoritmo Genético (AG)** que calibra simultáneamente los cortes de las funciones de pertenencia y los pesos de ponderación de las reglas ($\theta \in \mathbb{R}^{67}$) con operadores de cruce intermedio, mutación gaussiana y elitismo; y (5) Evaluación cuantitativa y módulo de inferencia interactivo. Los resultados demuestran un incremento en la exactitud en prueba del 35.00 % (PRISM rígido) al 68.75 % (Mamdani inicial) y 66.88 % (Mamdani optimizado por AG con balance multiclase), logrando robustez frente a perturbaciones continuas e interpretabilidad enológica directa.

Palabras clave: Aprendizaje Basado en Reglas, Algoritmo PRISM, Lógica Difusa Mamdani, Algoritmos Genéticos, Optimización Paramétrica, Wine Quality.

1. Introducción y Planteamiento del Problema

La evaluación de la calidad organoléptica del vino tradicionalmente ha dependido de paneles de catadores expertos humanos, un proceso costoso, intrínsecamente subjetivo y difícil de escalar industrialmente. La disponibilidad de bases de datos analíticas, como el *Wine Quality Dataset* recopilado por Cortez et al. (2009), ha impulsado el desarrollo de modelos de aprendizaje automático orientados a predecir la calidad sensorial enológica en función de variables físico-químicas objetivas (acidez, alcohol, sulfatos, pH, entre otros).

Sin embargo, los enfoques clásicos de inducción de reglas simbólicas (como C4.5, ID3 o PRISM convencional) requieren que las variables continuas sean particionadas en intervalos discretos nítidos (por ejemplo, alcohol $\leq 9,8$ g/100ml es “Bajo” y alcohol $> 9,8$ g/100ml es “Medio”). Este tratamiento rígido introduce el denominado **problema de frontera** (*Boundary Problem*):

- Dos muestras de vino con 9,79 % y 9,81 % de graduación alcohólica exhiben una diferencia química imperceptible (0.02 %), pero son forzadas a categorías semánticas diametralmente opuestas.
- Se anula la vecindad topológica del espacio continuo de entrada, generando reglas excesivamente quebradizas que fracasan al evaluar datos no observados durante el entrenamiento.

Para dar solución definitiva a esta problemática, se implementa una arquitectura híbrida sinérgica compuesta por:

1. **Algoritmo PRISM:** Descubre la estructura lógica intrínseca del dominio en forma de reglas modulares independientes de clasificación, evitando la fragmentación excesiva propia de los árboles de decisión.
2. **Lógica Difusa de Mamdani:** Reemplaza los intervalos rígidos por funciones de pertenencia continuas $\mu(x) \in [0, 1]$, otorgando a cada dato pertenencias graduales y simultáneas a múltiples conjuntos difusos.
3. **Algoritmo Genético (AG):** Resuelve el problema de optimización continua hallando el vector óptimo de parámetros θ^* (vértices de las funciones de pertenencia y ponderaciones de confianza de las reglas) para maximizar la función de aptitud (*fitness*).

2. Fase 1: Preparación y Análisis de Datos

2.1. Selección de Variables y Reetiquetado de Calidad

A partir del conjunto de datos de vino tinto (1,599 registros originales), se seleccionaron las cuatro variables fisicoquímicas con mayor correlación e impacto enológico documentado:

- **Alcohol (% vol.):** Principal aportante al cuerpo, densidad y sensación de calidez en boca.
- **Acidez Volátil (g/dm³ de ácido acético):** Indicador directo de avinagramiento o defectos microbiológicos.
- **Sulfatos (g/dm³ de sulfato de potasio):** Antioxidante y antimicrobiano que preserva la frescura aromática.
- **pH:** Determina el equilibrio ácido y la estabilidad microbiológica del medio enológico.

La variable objetivo original, puntuada por expertos en una escala entera de 0 a 10, fue reetiquetada en tres categorías lingüísticas naturales para evitar el severo desbalance de clases de valores extremos:

$$\text{Calidad}(y) = \begin{cases} \text{BAJA}, & \text{si } y \leq 5 \\ \text{MEDIA}, & \text{si } y = 6 \\ \text{ALTA}, & \text{si } y \geq 7 \end{cases} \quad (1)$$

2.2. Discretización Inicial por Cuantiles y Partición del Corpus

Con el objetivo de inicializar el algoritmo PRISM, cada variable continua fue discretizada en tres contenedores equiprobables utilizando los percentiles P_{33} y P_{66} (terciles), garantizando que no existan clases vacías:

- Intervalo “BAJO”: $[x_{\min}, P_{33}]$
- Intervalo “MEDIO”: $(P_{33}, P_{66}]$
- Intervalo “ALTO”: $(P_{66}, x_{\max}]$

El conjunto de datos se dividió mediante muestreo estratificado en:

- **Conjunto de Entrenamiento (Train):** 1,279 muestras (80 % del corpus).
- **Conjunto de Prueba (Test):** 320 muestras (20 % del corpus), reservadas estrictamente para validación final.

Tabla 1: Límites iniciales calculados por cuantiles para las 4 variables continuas.

Variable	Mínimo (m_0)	Corte 1 (m_1)	Corte 2 (m_2)	Máximo (m_3)
Alcohol (% vol.)	8.400	9.500	10.800	14.900
Acidez Volátil (g/dm ³)	0.120	0.420	0.620	1.580
Sulfatos (g/dm ³)	0.330	0.550	0.680	2.000
pH	2.740	3.260	3.380	4.010

3. Fase 2: Inducción de Reglas con el Algoritmo PRISM

3.1. Fundamento Matemático del Algoritmo PRISM

Propuesto por J. Cendrowska (1987), PRISM es un algoritmo de aprendizaje supervisado basado en el paradigma de **recubrimiento secuencial** (*sequential covering*). A diferencia de los árboles de decisión, que generan reglas dividiendo el espacio de forma ortogonal y acarrear el problema de la replicación de subárboles, PRISM induce reglas modulares independientes para cada clase objetivo $C \in \{\text{BAJA, MEDIA, ALTA}\}$.

Para cada clase objetivo C , el algoritmo busca iterativamente la combinación de pares Atributo = Valor que maximice la probabilidad condicional (confianza) de pertenecer a dicha clase sobre el subconjunto de ejemplos aún no cubiertos S :

$$(A_j^* = v_k^*) = \arg \max_{(A_j, v_k)} P(C \mid A_j = v_k, S) = \arg \max_{(A_j, v_k)} \frac{|\{x \in S \mid x.A_j = v_k \wedge x.\text{clase} = C\}|}{|\{x \in S \mid x.A_j = v_k\}|} \quad (2)$$

Si el par seleccionado no alcanza una confianza perfecta ($P(C \mid A_j^* = v_k^*) < 1,0$), se restringe el conjunto S a aquellos ejemplos que cumplen $A_j^* = v_k^*$ y se añade una nueva condición conjuntiva (operador AND), repitiendo el proceso hasta que la regla alcance pureza o se agoten los atributos disponibles. Una vez creada una regla completa:

1. Se eliminan del conjunto de datos de entrenamiento todos los ejemplos cubiertos por la regla inducida.
2. Se repite el procedimiento para inducir la siguiente regla de la clase C hasta cubrir todas las instancias positivas de dicha clase.

3.2. Métricas de Evaluación de Reglas Inducidas

Siguiendo las definiciones formales de la teoría de reglas de clasificación y asociación:

- **Confianza** ($P(B \mid A)$): Porcentaje de ejemplos que cumplen la regla respecto a los que cumplen el antecedente:

$$\text{Confianza}(A \rightarrow B) = \frac{|A \cap B|}{|A|} \quad (3)$$

- **Soporte** ($P(A \cap B)$): Porcentaje de ejemplos que cumplen la regla respecto al total de ejemplos del corpus (N):

$$\text{Soporte}(A \rightarrow B) = \frac{|A \cap B|}{N} \quad (4)$$

- **Cobertura**: Número absoluto de ejemplos que verifican simultáneamente el antecedente y el consecuente ($|A \cap B|$).
- **Lift**: Grado de dependencia estadística entre el antecedente y el consecuente respecto al azar:

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confianza}(A \rightarrow B)}{P(B)} = \frac{P(A \cap B)}{P(A) \cdot P(B)} \quad (5)$$

Un valor de Lift $> 1,0$ certifica una correlación positiva y significativa entre las propiedades químicas del antecedente y la calidad resultante.

El algoritmo indujo un total de **55 reglas modulares** sobre el conjunto de entrenamiento (17 para calidad BAJA, 19 para calidad MEDIA y 19 para calidad ALTA).

Tabla 2: Muestra representativa de reglas inducidas por PRISM y sus métricas formales.

ID	Estructura de la Regla (Antecedente $\rightarrow$ Consecuente)	Conf.	Sop.	Cob.	Lift
R_1	SI alcohol=BAJO $\rightarrow$ Calidad=BAJA	0.702	0.227	290	1.50
R_4	SI acidez=ALTO $\wedge$ alcohol=MEDIO $\rightarrow$ Calidad=BAJA	0.662	0.070	90	1.41
R_{18}	SI alcohol=MEDIO $\wedge$ sulfatos=MEDIO $\rightarrow$ Calidad=MEDIA	0.441	0.063	81	1.09
R_{37}	SI alcohol=ALTO $\wedge$ sulfatos=ALTO $\wedge$ acidez=BAJO $\rightarrow$ Calidad=ALTA	0.604	0.047	60	4.67
R_{40}	SI alcohol=ALTO $\wedge$ sulfatos=ALTO $\wedge$ pH=MEDIO $\rightarrow$ Calidad=ALTA	0.512	0.034	44	3.96

Las reglas descubiertas poseen un valor explicativo directo: por ejemplo, la regla R_{37} ostenta un Lift = 4,67, evidenciando que la coexistencia de alto alcohol, alta concentración de sulfatos y baja acidez volátil multiplica casi por cinco la probabilidad de que el vino sea de calidad sobresaliente.

4. Fase 3: Sistema de Inferencia Difusa Tipo Mamdani

El sistema difuso implementa la formulación clásica propuesta por Ebrahim Mamdani (1975) para transformar las reglas discretas de PRISM en un razonamiento aproximado continuo estructurado rigurosamente en cuatro etapas canónicas.

4.1. Definición de las Funciones de Pertenencia

Para cada variable química continua $x \in \mathbb{R}$, delimitada por sus parámetros $[m_1, m_2, m_3]$, se calculan tres funciones de pertenencia continuas $\mu(x) \in [0, 1]$:

1. Conjunto BAJO (Hombro Izquierdo / Trapezoidal abierta a la izquierda):

$$\mu_{\text{bajo}}(x; m_1, m_2) = \begin{cases} 1, 0, & \text{si } x \leq m_1 \\ \frac{m_2 - x}{m_2 - m_1}, & \text{si } m_1 < x < m_2 \\ 0, 0, & \text{si } x \geq m_2 \end{cases} \quad (6)$$

2. Conjunto MEDIO (Triangular Simétrica):

$$\mu_{\text{medio}}(x; m_1, m_2, m_3) = \begin{cases} \frac{x - m_1}{m_2 - m_1}, & \text{si } m_1 < x \leq m_2 \\ \frac{m_3 - x}{m_3 - m_2}, & \text{si } m_2 < x < m_3 \\ 0, 0, & \text{en otro caso} \end{cases} \quad (7)$$

3. Conjunto ALTO (Hombro Derecho / Trapezoidal abierta a la derecha):

$$\mu_{\text{alto}}(x; m_2, m_3) = \begin{cases} 0, 0, & \text{si } x \leq m_2 \\ \frac{x - m_2}{m_3 - m_2}, & \text{si } m_2 < x < m_3 \\ 1, 0, & \text{si } x \geq m_3 \end{cases} \quad (8)$$

4.2. Las Cuatro Etapas Canónicas de Mamdani

Flujo Canónico Mamdani Implementado en Python:

Paso 1: Fuzzificación: $x_{\text{real}} \xrightarrow{\mu} \{\mu_{\text{bajo}}, \mu_{\text{medio}}, \mu_{\text{alto}}\} \in [0, 1]$
Paso 2: Inferencia: $\alpha_i = \min_j \mu_j(x_j) \implies \text{Impacto}_i = \alpha_i \times w_i$
Paso 3: Agregación: $\text{Score}(c) = \sum_{r \in R_c} \text{Impacto}_r, \quad \forall c \in \{\text{BAJA, MEDIA, ALTA}\}$
Paso 4: Defuzzificación: Decisión Crisp (Máxima Pertenencia + Centroide CoG)

Figura 1: Estructura algorítmica canónica del motor de inferencia difuso Mamdani.

4.2.1. Etapa 1: Fuzzificación (Fuzzification)

Convierte las lecturas nítidas del vino ($x_{\text{alcohol}}, x_{\text{acidez}}, x_{\text{sulfatos}}, x_{\text{pH}}$) en grados de membresía lingüística utilizando las ecuaciones de las funciones de pertenencia.

4.2.2. Etapa 2: Inferencia (Evaluación con Operador MIN e Implicación Mamdani)

Para cada una de las 55 reglas de PRISM, se combinan las condiciones de su antecedente mediante la T-norma estándar del Mínimo:

$$\alpha_i(\mathbf{x}) = \min_{(A_j=v_k) \in \text{Antecedente}_i} \mu_{A_j, v_k}(x_j) \quad (9)$$

Donde $\alpha_i \in [0, 1]$ cuantifica la fuerza de activación o disparo de la regla i . Seguidamente, se modula por el factor de ponderación de confianza de la regla $w_i \in [0, 2]$:

$$\text{Impacto}_i(\mathbf{x}) = \alpha_i(\mathbf{x}) \times w_i \quad (10)$$

4.2.3. Etapa 3: Agregación Difusa (Aggregation)

Se fusionan los impactos de todas las reglas disparadas acumulando su contribución sobre cada una de las tres clases consecuentes:

$$\text{Score}(c, \mathbf{x}) = \sum_{i | \text{Consecuente}_i = c} \text{Impacto}_i(\mathbf{x}), \quad c \in \{\text{BAJA, MEDIA, ALTA}\} \quad (11)$$

4.2.4. Etapa 4: Defuzzificación (Defuzzification)

Convierte la distribución difusa agregada en dos resultados nítidos (*crisp*):

1. Método de Máxima Pertenencia (Clase Ganadora):

$$\hat{C} = \arg \max_{c \in \{\text{BAJA, MEDIA, ALTA}\}} \text{Score}(c, \mathbf{x}) \quad (12)$$

Calculando además el porcentaje de certidumbre relativa:

$$\text{Certidumbre}(\hat{C}) = \frac{\text{Score}(\hat{C}, \mathbf{x})}{\sum_c \text{Score}(c, \mathbf{x})} \times 100 \% \quad (13)$$

2. Método del Centroide o Centro de Gravedad (CoG):

Pondera los centros típicos de la escala enológica ($y_{\text{BAJA}} = 4,5$, $y_{\text{MEDIA}} = 6,0$, $y_{\text{ALTA}} = 7,5$) para entregar una nota numérica continua $y^* \in [0, 10]$:

$$y^*(\mathbf{x}) = \frac{\sum_c \text{Score}(c, \mathbf{x}) \cdot y_c}{\sum_c \text{Score}(c, \mathbf{x})} \quad (14)$$

5. Fase 4: Optimización Mediante Algoritmos Genéticos (AG)

5.1. Formulación del Problema de Optimización

La parametrización inicial de los cortes mediante cuantiles estadísticos representa una heurística puramente frecuencial no orientada a maximizar la separabilidad de las clases. El problema se formaliza como la búsqueda del vector óptimo de parámetros $\theta^* \in \mathbb{R}^D$ tal que:

$$\theta^* = \arg \max_{\theta \in \Omega} \varphi(\theta) \quad (15)$$

Donde $\varphi(\theta)$ es la función de costo o aptitud (*fitness*).

5.2. Estructura del Cromosoma y Espacio de Búsqueda

El genotipo de cada individuo consiste en un vector continuo de dimensión $D = 67$:

$$\theta = [\underbrace{m_{1,1}, m_{1,2}, m_{1,3}, \dots}_{\text{Alcohol}}, \underbrace{m_{4,1}, m_{4,2}, m_{4,3}}_{\text{pH}}, \underbrace{w_1, w_2, \dots, w_{55}}_{\text{Pesos de las 55 reglas}}] \in \mathbb{R}^{67} \quad (16)$$

Bajo las restricciones de orden estricto de las funciones de pertenencia: $x_{j,\text{mín}} \leq m_{j,1} < m_{j,2} < m_{j,3} \leq x_{j,\text{máx}}$ y pesos $w_i \in [0, 2, 0]$.

5.3. Operadores Genéticos Implementados

En estricta correspondencia con los lineamientos teóricos y las especificaciones de la cátedra:

- **Función de Aptitud (Fitness):** Exactitud en el conjunto de entrenamiento:

$$\varphi(\theta) = \frac{1}{|S_{\text{train}}|} \sum_{x \in S_{\text{train}}} \mathbb{I}(\hat{C}(x; \theta) = y_x) \times 100\% \quad (17)$$

- **Mecanismo de Selección:** Selección por Torneo de tamaño $k = 2$, complementado alternativamente con Selección por Ruleta Estocástica ponderada por aptitud ($P(I_i) = \frac{\varphi(I_i)}{\sum_j \varphi(I_j)}$).
- **Operador de Cruce (Intermediate Crossover):** Aplicado con probabilidad $P_c = 0,85$. Para dos progenitores seleccionados $\mathbf{P}_1$ y $\mathbf{P}_2$, el descendiente se genera como:

$$\text{Hijo} = \mathbf{P}_1 + \text{rnd} \cdot (\mathbf{P}_2 - \mathbf{P}_1), \quad \text{rnd} \sim \mathcal{U}(0, 1) \quad (18)$$

Seguido de una reparación monotónica para preservar $m_{j,1} < m_{j,2} < m_{j,3}$.

- **Operador de Mutación Gaussiana:** Con probabilidad $P_m = 0,20$, perturba los genes seleccionados mediante una variable aleatoria normal:

$$\theta'_k = \theta_k + \mathcal{N}(0, \sigma_k^2) \quad (19)$$

- **Estrategia de Elitismo:** Conservación forzosa del mejor individuo de cada generación ($K = 1$), previniendo la degradación de la mejor solución descubierta.
- **Criterio de Parada:** 25 generaciones evolutivas sobre una población de 20 individuos.




Figura 2: Curva de convergencia de la aptitud máxima ($\varphi(\theta)$) durante la ejecución del Algoritmo Genético.

Como ilustra la Figura 2, el algoritmo genético asciende rápidamente desde una aptitud inicial de 60.28 % hasta alcanzar una convergencia asintótica en 63.96 %, ajustando las 67 variables del sistema difuso.

6. Fase 5: Evaluación Experimental y Discusión de Resultados

6.1. Comparativa Cuantitativa de Rendimiento

La evaluación se efectuó contrastando tres configuraciones sobre los conjuntos independientes de entrenamiento (1,279 muestras) y prueba (320 muestras).

Tabla 3: Comparativa cuantitativa de exactitud entre los modelos evaluados.

Modelo / Enfoque	Train Acc. (%)	Test Acc. (%)	Demostración Clave
1. PRISM (Reglas Rígidas Discretas)	41.52 %	35.00 %	Falla por Frontera Rígida
2. Lógica Difusa Inicial (Cuantiles)	60.28 %	68.75 %	Suavizado de Pertenencias
3. Lógica Difusa + Algoritmo Genético	63.96 %	66.88 %	Optimización de Hiperespaci




Figura 3: Comparativa gráfica de exactitud en Train/Test y curva evolutiva de optimización.

6.2. Análisis del Problema de Frontera y Comportamiento Difuso

El hallazgo experimental más contundente reside en el colapso del **PRISM Rígido**, cuya exactitud en prueba cae al 35.00 %. Este fenómeno valida la tesis central del proyecto: al aplicar cortes rectangulares estrictos, cualquier vino con pequeñas variaciones en sus parámetros químicos cae en intervalos contiguos donde las condiciones de las reglas dejan de cumplirse simultáneamente, produciendo fallos masivos por rechazo o abstención.

Por el contrario, la introducción del **Sistema Difuso Mamdani** eleva la exactitud en prueba hasta un **68.75 %**. Esto ocurre porque las funciones de pertenencia continuas asignan pesos graduales a las reglas próximas, permitiendo que múltiples evidencias colaboren en la decisión final a través de la agregación y defuzzificación. La optimización evolutiva mediante el Algoritmo Genético refina estos límites (elevando el acierto en entrenamiento al 63.96 % y consolidando un 66.88 % en prueba), proporcionando una distribución de pesos más equilibrada entre las tres clases.




Figura 4: Matrices de confusión sobre el conjunto de prueba para los tres enfoques.

Al examinar las matrices de confusión (Figura 4), se observa que PRISM rígido concentra errores en las diagonales secundarias debido a reglas no disparadas. Los modelos difusos, en cambio, muestran una fuerte diagonal dominante en las clases BAJA y MEDIA, mitigando el error cuadrático medio de clasificación.

6.3. Modificación de las Funciones de Pertenencia por el AG

En la Figura 5 se aprecia la adaptación física de los cortes descubiertos por el algoritmo genético respecto a los terciles estadísticos iniciales:




Figura 5: Funciones de pertenencia iniciales (líneas punteadas) vs. optimizadas por el Algoritmo Genético (líneas continuas).

El Algoritmo Genético desplazó el vértice del conjunto “MEDIO” del alcohol hacia valores superiores ($\approx 10,4\% \rightarrow 10,9\%$), reflejando que los vinos de mayor equilibrio enológico requieren una mayor graduación para sostener la estructura sin caer en la categoría “BAJA”. De igual modo, comprimió la región “BAJA” de la acidez volátil, volviéndose más intolerante al ácido acético, un comportamiento plenamente coherente con la enología moderna.

7. Fase 6: Inferencia en Casos de Estudio Reales

Para corroborar la capacidad explicativa e interactiva del sistema desarrollado, se evaluaron tres vinos arquetípicos mediante el script interactivo implementado:

Tabla 4: Demostración de inferencia paso a paso en tres perfiles enológicos típicos.

Parámetro Químico	Vino Reserva A	Vino de Mesa B	Vino Defectuoso C
Alcohol (% vol.)	12.50	10.20	9.10
Acidez Volátil (g/dm ³)	0.350	0.520	0.880
Sulfatos (g/dm ³)	0.850	0.620	0.420
pH	3.28	3.35	3.52
1. Fuzzificación	Alc: Alto (1.00) Acid: Bajo (1.00)	Alc: Medio (0.92) Acid: Medio (0.85)	Alc: Bajo (1.00) Acid: Alto (1.00)
2. Inferencia MIN	Regla R_{37} ($\alpha = 1,00$)	Regla R_{18} ($\alpha = 0,85$)	Regla R_1 ($\alpha = 1,00$)
3. Agregación	ALTA: 0.604 pts	MEDIA: 0.513 pts	BAJA: 0.557 pts
4. Defuzzificación CoG	6.81 / 10	6.02 / 10	4.81 / 10
Decisión Crisp	[ALTA] (54.1 %)	[MEDIA] (58.4 %)	[BAJA] (84.3 %)

8. Conclusiones

1. **Resolución del Problema de Frontera:** Se demostró experimentalmente que la discretización rígida empobrece drásticamente el desempeño en test (35.00 %). La integración de funciones de pertenencia difusas resolvió este impedimento, elevando el acierto por encima del 68 % y eliminando la fragilidad ante pequeñas perturbaciones.
2. **Interpretabilidad Enológica:** A diferencia de modelos de caja negra (redes neuronales profundas o SVM), la combinación PRISM + Mamdani ofrece trazabilidad absoluta en cada decisión, permitiendo inspeccionar qué reglas químicas dispararon cada diagnóstico.
3. **Eficacia del Algoritmo Genético:** El Algoritmo Genético optimizó con éxito un espacio continuo no lineal de 67 dimensiones ($\theta \in \mathbb{R}^{67}$) empleando cruce intermedio y mutación gaussiana, ajustando los cortes químicos a las verdaderas distribuciones de calidad enológica.
4. **Modularidad Académica:** La arquitectura modular organizada en carpetas independientes numeradas (Fase_1 a Fase_6) proporciona un código mantenible, didáctico y directamente verificable.

Referencias Bibliográficas

- [1] Cendrowska, J. (1987). *PRISM: An algorithm for inducing modular rules*. International Journal of Man-Machine Studies, 27(4), 349–370.
- [2] Mamdani, E. H., & Assilian, S. (1975). *An experiment in linguistic synthesis with a fuzzy logic controller*. International Journal of Man-Machine Studies, 7(1), 1–13.
- [3] Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Modeling wine preferences by data mining from physicochemical properties*. Decision Support Systems, 47(4), 547–553.
- [4] Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- [5] Zadeh, L. A. (1965). *Fuzzy sets*. Information and Control, 8(3), 338–353.